

分类模型

第一部分 线性分类模型

张朝晖

2018-2019学年 20180918-0919

1.分类模块

产生式分类模型

A.贝叶斯分类模型

判别式分类模型

线性分类模型

- B. Fisher判别分类
- C. 感知器分类模型
- D. 大间隔分类模型(线性SVM)

非线性分类模型

- E. 核SVM(非线性SVM)
- F. 核Fisher判别分类
- G. 神经网络

其它分类模型

- H.KNN分类模型
- I.决策树分类模型
- J.Logistic回归
- K.Softmax回归

2.聚类模块

- L.K-均值聚类
- M.高斯混合聚类
- N.DBSCAN聚类
- O.层次聚类

3.回归模块

- P.KNN回归
- Q.回归树
- R.最小二乘线性回归
- S.岭回归
- T.LASSO回归

4.集成学习

- U.Bagging
- V.随机森林
- W.Boosting

5.特征工程

- X.主成分分析(PCA)
- ...

6.评价模块

混淆矩阵(及其相关指标)、ROC曲线、交叉验证

主要内容

A. 引言

B. Fisher线性判别分析

C. 感知器

D. 线性支持向量机(线性SVM)

Support Vector Machine: SVM

学习要求:

- 理解SVM分类模型构建的基本思想
- 掌握SVM目标函数的构造形式、意义
- 掌握SVM分类模型的学习步骤、使用流程
- 掌握SVM进行超参数寻优的典型方法
- 能够熟练应用SVM进行分类

关键词:

- 分类间隔、分类边界、判别函数
- 训练样本集的错分程度
- 分类超平面、超平面法向量、超参数
- 支持向量、非支持向量
- 判别函数、分类边界

➤ SVM(Support Vector Machine)是支持向量机的简称。
“机”,对应机器学习中的“机器”,是“算法”的意思。

所谓支持向量机就是一种与“支持向量”有关的机器学习算法。

➤ SVM 的求解最后转化成凸二次规划问题的求解,因此SVM的解是全局唯一的最优解。

➤ SVM在解决小样本(样本数<特征维数)、非线性、高维模式分类问题中表现出许多特有的优势,并能够推广应用到函数拟合(回归)等其它机器学习问题中。

➤ SVM 用于分类,就是 SVC (Support Vector Classification); 用于回归就是SVR (Support Vector Regression)。

第1部分

两类别分类情况下的线性SVC

主要内容

- 1 两类别分类问题：线性可分情况
- 2 两类别分类问题：近似线性可分情况
- 3 多类别的线性SVM
- 4 应用举例

SVM始于两类问题的解决需求

两类别分类问题的描述：

给定训练集 $T = \{(\mathbf{x}_1, y_1), \dots, (\mathbf{x}_N, y_N)\}$

$$\text{其中} \begin{cases} \mathbf{x}_i \in R^d \\ y_i \in \mathcal{Y} = \{1, -1\} \end{cases} \quad i = 1, 2, \dots, N$$

要求：寻找 R^d 空间上的一个实值函数 $g(\mathbf{x})$, 从而可用
决策函数 $f(\mathbf{x}) = \text{sgn}(g(\mathbf{x})) : R^d \rightarrow \mathcal{Y}$;
推断任意输入 \mathbf{x} 对应的输出值 y .

线性可分问题-定义:

给定**训练集** $T = \{(\mathbf{x}_1, y_1), \dots, (\mathbf{x}_N, y_N)\}$

其中 $\mathbf{x}_i \in R^d, i = 1, 2, \dots, N$


$y_i \in \mathcal{Y} = \{1, -1\}$

若存在 $\omega \in R^d, b \in R$,以及正数 ε , 使得

$$\begin{cases} \text{对于所有 } y_i = +1 \text{ 的样本 } \mathbf{x}_i, \text{ 有 } g(\mathbf{x}_i) = \omega \bullet \mathbf{x}_i + b \geq \varepsilon \\ \text{对于所有 } y_i = -1 \text{ 的样本 } \mathbf{x}_i, \text{ 有 } g(\mathbf{x}_i) = \omega \bullet \mathbf{x}_i + b \leq -\varepsilon. \end{cases}$$


则称**训练集** T 线性可分。

1. 例：二维、两类、线性可分情况



问题：可能存在许多分类边界（决策边界），若将两类完全分开，应当选择哪一个？


➤ 较差的分类边界(如图)



➤ 较好的分类边界:

分类间隔 (margin) 尽可能大;

分类边界尽可能远离两类样本数据



➤ 最优分类边界:

能将两类无错误分开;

分类间隔(margin)最大

➤ H -----最优分类线;

➤ H_1, H_2 -----平行于 H 、且经过各类训练样本集中离 H 最近的训练样本

➤ 分类间隔(margin)----- H_1, H_2 之间的距离

➤ 推广到高维空间: 最优边界就变为最优超平面
(*optimal hyperplane*)

如何找到最优分类边界?

分类边界 $w \cdot x + b = 0$

判别函数 $g(x) = w \cdot x + b$

2. 线性SVM的分类间隔

线性可分训练样本集 $\{\mathbf{x}_i, y_i\} \quad i=1, \dots, N \quad \mathbf{x}_i \in R^d$
类别标号 $y_i \in \{-1, 1\}$

d 维空间的线性判别函数 $g(\mathbf{x}) = \mathbf{w} \cdot \mathbf{x} + b$

判别函数归一化 $\begin{cases} \text{两类所有样本满足} & |g(\mathbf{x}_i)| \geq 1 \\ \text{离分类面最近样本} & |g(\mathbf{x}_i)| = 1 \end{cases}$

训练样本线性可分 $\begin{cases} g(\mathbf{x}_i) \geq 1 & \text{对于 } y_i = 1 \\ g(\mathbf{x}_i) \leq -1 & \text{对于 } y_i = -1 \end{cases}$


$$\Rightarrow y_i \cdot g(\mathbf{x}_i) \geq 1$$

$$\Rightarrow y_i \cdot [\mathbf{w} \cdot \mathbf{x}_i + b] - 1 \geq 0$$

最优分类面 H : $\mathbf{w} \cdot \mathbf{x} + b = 0$

正平面 H_1 : $\mathbf{w} \cdot \mathbf{x} + b = 1$


负平面 H_2 : $\mathbf{w} \cdot \mathbf{x} + b = -1$



设 $\begin{cases} \mathbf{x}^+ \text{ 为正平面 } H_1 \text{ 上任意点,} \\ \mathbf{x}^- \text{ 为负平面 } H_2 \text{ 上最接近 } \mathbf{x}^+ \text{ 的点, } \mathbf{x}^+ = \mathbf{x}^- + \lambda \mathbf{w} \end{cases}$

则 $\begin{cases} \text{正平面上} & \mathbf{w} \cdot \mathbf{x}^+ + b = 1 \\ \text{负平面上} & \mathbf{w} \cdot \mathbf{x}^- + b = -1 \\ \text{两平面间隔} & \text{margin} = \|\mathbf{x}^+ - \mathbf{x}^-\| = \|\lambda \mathbf{w}\| = \lambda \|\mathbf{w}\| \end{cases}$

$$\begin{cases} \text{正平面上: } \mathbf{w} \cdot \mathbf{x}^+ + b = 1 \\ \text{负平面上: } \mathbf{w} \cdot \mathbf{x}^- + b = -1 \\ \mathbf{x}^+ = \mathbf{x}^- + \lambda \mathbf{w} \end{cases}$$



$$\rightarrow \mathbf{w} \cdot (\mathbf{x}^- + \lambda \mathbf{w}) + b = 1$$

$$\rightarrow \mathbf{w} \cdot \mathbf{x}^- + b + \lambda \mathbf{w} \cdot \mathbf{w} = 1$$

$$\rightarrow -1 + \lambda \mathbf{w} \cdot \mathbf{w} = 1$$

$$\rightarrow \lambda = \frac{2}{\mathbf{w} \cdot \mathbf{w}} = \frac{2}{\|\mathbf{w}\|^2}$$

分类间隔 $margin = \|\mathbf{x}^+ - \mathbf{x}^-\| = \|\lambda \mathbf{w}\| = \frac{2}{\|\mathbf{w}\|}$

3. 线性SVM—目标函数的构造

最优分类边界

$$\left\{ \begin{array}{l} \text{分类间隔最大 } \text{margin} = \frac{2}{\|\mathbf{w}\|} \quad \Leftrightarrow \quad \text{使 } \|\mathbf{w}\| \text{ (或 } \|\mathbf{w}\|^2 \text{) 最小} \\ \text{训练样本线性可分 (均正确分类)} \quad \Leftrightarrow \quad y_i \cdot (\mathbf{w} \cdot \mathbf{x}_i + b) - 1 \geq 0 \\ \quad \quad \quad \quad \quad \quad \quad \quad \quad \quad \quad \quad \quad \quad \quad i = 1, 2, \dots, N \end{array} \right.$$

$$\phi(\mathbf{w}) = \frac{1}{2} \|\mathbf{w}\|^2 = \frac{1}{2} (\mathbf{w} \cdot \mathbf{w}) = \frac{1}{2} \mathbf{w}^T \mathbf{w}$$

原始问题的目标函数 (线性可分问题的最大间隔法)

约束优化问题 (凸二次规划)

如何求解?

$$\left\{ \begin{array}{l} \min_{\mathbf{w}, b} \quad \phi(\mathbf{w}) = \frac{1}{2} (\mathbf{w} \cdot \mathbf{w}) \\ \text{s.t.} \quad y_i \cdot (\mathbf{w} \cdot \mathbf{x}_i + b) - 1 \geq 0 \quad i = 1, 2, \dots, n \end{array} \right.$$


4. 线性SVM—目标函数的求解

构造*Lagrange*辅助目标函数，将**原始问题**转化为**对偶问题**。

$$L(\mathbf{w}, b, \alpha) = \frac{1}{2}(\mathbf{w} \cdot \mathbf{w}) - \sum_{i=1}^N \alpha_i \{y_i \cdot [(\mathbf{w} \cdot \mathbf{x}_i) + b] - 1\}$$

其中**非负***Lagrange*乘子向量 $\alpha = [\alpha_1 \ \cdots \ \alpha_N]^T$

显然： $L(\mathbf{w}, b, \alpha) \leq \frac{1}{2}(\mathbf{w} \cdot \mathbf{w})$



原始问题等价于：

$$\min_{\mathbf{w}, b} \max_{\alpha} L(\mathbf{w}, b, \alpha) = \frac{1}{2}(\mathbf{w} \cdot \mathbf{w}) - \sum_{i=1}^N \alpha_i \{y_i \cdot [(\mathbf{w} \cdot \mathbf{x}_i) + b] - 1\}$$

$$\begin{aligned}
L(\mathbf{w}, b, \alpha) &= \frac{1}{2}(\mathbf{w} \cdot \mathbf{w}) - \sum_{i=1}^N \alpha_i \{y_i \cdot [(\mathbf{w} \cdot \mathbf{x}_i) + b] - 1\} \\
&= \frac{1}{2}(\mathbf{w}^T \mathbf{w}) - \sum_{i=1}^N \alpha_i y_i \mathbf{w}^T \mathbf{x}_i - b \sum_{i=1}^N \alpha_i y_i + \sum_{i=1}^N \alpha_i
\end{aligned}$$

$L(\mathbf{w}, b, \alpha)$ 在最优解处满足:

$$\left\{ \begin{array}{l} \text{条件 1} \quad \frac{\partial L(\mathbf{w}, b, \alpha)}{\partial \mathbf{w}} = 0 \rightarrow \mathbf{w} = \sum_{i=1}^N \alpha_i y_i \mathbf{x}_i \\ \text{条件 2} \quad \frac{\partial L(\mathbf{w}, b, \alpha)}{\partial b} = 0 \rightarrow \sum_{i=1}^N \alpha_i y_i = 0 \end{array} \right.$$

该条件下, $L(\mathbf{w}, b, \alpha)$ 为

$$Q(\alpha) = \sum_{i=1}^N \alpha_i + \frac{1}{2} (\mathbf{w}^T \mathbf{w}) - \mathbf{w}^T \sum_{i=1}^N \alpha_i y_i \mathbf{x}_i$$

$$= \sum_{i=1}^N \alpha_i - \frac{1}{2} \mathbf{w}^T \sum_{i=1}^N \alpha_i y_i \mathbf{x}_i$$

$$= \sum_{i=1}^N \alpha_i - \frac{1}{2} \left(\sum_{j=1}^N \alpha_j y_j \mathbf{x}_j \right)^T \sum_{i=1}^N \alpha_i y_i \mathbf{x}_i$$


$$= \sum_{i=1}^N \alpha_i - \frac{1}{2} \left(\sum_{j=1}^N \sum_{i=1}^N \alpha_i \alpha_j y_i y_j \mathbf{x}_j^T \mathbf{x}_i \right)$$

$$= \sum_{i=1}^N \alpha_i - \frac{1}{2} \sum_{j=1}^N \sum_{i=1}^N \alpha_i \alpha_j y_i y_j (\mathbf{x}_j \cdot \mathbf{x}_i)$$

对偶问题

$$\begin{array}{ll} \max_{\alpha} & Q(\alpha) = \sum_{i=1}^N \alpha_i - \frac{1}{2} \sum_{j=1}^N \sum_{i=1}^N \alpha_i \alpha_j y_i y_j (\mathbf{x}_j \cdot \mathbf{x}_i) \\ s.t. & \begin{cases} (1) \sum_{i=1}^N \alpha_i y_i = 0 \\ (2) \alpha_i \geq 0 \quad \text{对于 } i = 1, \dots, N \end{cases} \end{array}$$

等价形式



对偶问题


$$\begin{array}{ll} \min_{\alpha} & W(\alpha) = \frac{1}{2} \sum_{j=1}^N \sum_{i=1}^N \alpha_i \alpha_j y_i y_j (\mathbf{x}_j \cdot \mathbf{x}_i) - \sum_{i=1}^N \alpha_i \\ s.t. & \begin{cases} (1) \sum_{i=1}^N \alpha_i y_i = 0 \\ (2) -\alpha_i \leq 0 \quad \text{对于 } i = 1, \dots, N \end{cases} \end{array}$$

解得**非负**乘子向量的最优解: $\alpha^* = [\alpha_1^* \quad \cdots \quad \alpha_N^*]^T$

线性SVM中，判别函数的最优参数 w^* 、 b^* 的确定：

$$(1) \quad w^* = \sum_{i=1}^N \alpha_i^* y_i x_i$$

$\alpha^* = [\alpha_1^* \quad \cdots \quad \alpha_N^*]^T$ 中多数分量为0



对 w^* 有贡献的只有占少数的非零 α_i^*

相应地，对应非零 α_i^* 的训练样本就称为**支持向量**(*Support Vector*)

作为支持向量的训练样本就位于 H_1, H_2 超平面。

线性SVM中，判别函数的最优参数 w^* 、 b^* 的确定：

(2) b^* 的确定


找到所有非零的 α_i^* 对应的支持向量，构成集合：

$$U = \{(\mathbf{x}_i, y_i) | (\mathbf{x}_i, y_i) \in \text{训练集} T, \text{ 并且 } \alpha_i^* > 0\}$$

对于 $\forall (\mathbf{x}_i, y_i) \in U$ ，必有： $y_i = \mathbf{w}^* \cdot \mathbf{x}_i + b^*$

为了确保稳定性，取平均：

$$b^* = \frac{1}{\#U} \sum_{(\mathbf{x}_i, y_i) \in U} [y_i - \mathbf{w}^* \cdot \mathbf{x}_i]$$




$\#U$ ----集合 U 中元素数目(或表示为 $|U|$)

原始问题的目标函数(线性可分问题的最大间隔法)

$$\begin{cases} \min_{\mathbf{w}, b} \phi(\mathbf{w}) = \frac{1}{2}(\mathbf{w} \cdot \mathbf{w}) \\ s.t. \quad y_i \cdot (\mathbf{w} \cdot \mathbf{x}_i + b) - 1 \geq 0 \quad i = 1, 2, \dots, n \end{cases}$$

非负Lagrange乘子向量的最优解: $\alpha^* = [\alpha_1^* \quad \dots \quad \alpha_N^*]^T$



$$\text{最优分类边界 } (\mathbf{w}^* \cdot \mathbf{x}) + b^* = 0 \quad \begin{cases} \mathbf{w}^* = \sum_{i=1}^N \alpha_i^* y_i \mathbf{x}_i \\ b^* = \frac{1}{\#U} \sum_{(\mathbf{x}_i, y_i) \in U} [y_i - \mathbf{w}^* \cdot \mathbf{x}_i] \\ U = \{(\mathbf{x}_i, y_i) \mid (\mathbf{x}_i, y_i) \in \text{训练集 } T, \text{ 并且 } \alpha_i^* > 0\} \end{cases}$$

$$\text{判别函数 } g(\mathbf{x}) = (\mathbf{w}^* \cdot \mathbf{x}) + b^* = \sum_{i=1}^N \alpha_i^* y_i (\mathbf{x}_i \cdot \mathbf{x}) + b$$

$$f(\mathbf{x}) = \text{sgn}[(\mathbf{w}^* \cdot \mathbf{x}) + b^*] = \text{sgn}\left\{\sum_{i=1}^N \alpha_i^* y_i (\mathbf{x}_i \cdot \mathbf{x}) + b^*\right\}$$

5. 利用线性SVM进行分类

对于未知类别的测试样本 \mathbf{x} ,

$$\text{若 } f(\mathbf{x}) = \text{sgn}\left[\left(\mathbf{w}^* \cdot \mathbf{x}\right) + b^*\right] = 1$$

则 \mathbf{x} 决策为第一类； 否则 \mathbf{x} 决策为第二类。

6.线性可分SVC算法

(1) 给定训练样本集 $T = \{(\mathbf{x}_1, y_1), \dots, (\mathbf{x}_N, y_N)\}$

其中 $\mathbf{x}_i \in R^d, y_i \in \mathcal{Y} = \{1, -1\}, i = 1, \dots, N$

训练样本的
预处理

(2) 构造并求解凸二次规划问题

$$\left\{ \begin{array}{l} \min_{\alpha} . \quad W(\alpha) = \frac{1}{2} \sum_{j=1}^N \sum_{i=1}^N \alpha_i \alpha_j y_i y_j (\mathbf{x}_j \cdot \mathbf{x}_i) - \sum_{i=1}^N \alpha_i \\ s.t. \quad \left\{ \begin{array}{l} (1) \quad \sum_{i=1}^N \alpha_i y_i = 0 \\ (2) \quad -\alpha_i \leq 0 \quad \text{对于 } i = 1, \dots, N \end{array} \right. \end{array} \right.$$

得解 $\alpha^* = [\alpha_1^*, \dots, \alpha_N^*]^T$

(3) 计算 $\mathbf{w}^* = \sum_{j=1}^N \alpha_j^* y_j \mathbf{x}_j$

(4) 计算 $b^* = \frac{1}{\#U} \sum_{(\mathbf{x}_i, y_i) \in U} [y_i - \mathbf{w}^* \cdot \mathbf{x}_i]$

其中 $U = \{(\mathbf{x}_i, y_i) \mid (\mathbf{x}_i, y_i) \in \text{训练集 } T, \text{ 并且 } \alpha_i^* > 0\}$

(5) 分类模型的使用:

$$g(\mathbf{x}) = (\mathbf{w}^* \cdot \mathbf{x}) + b^* = \sum_{i=1}^N \alpha_i^* y_i (\mathbf{x}_i \cdot \mathbf{x}) + b^*$$

对于未知类别的测试样本 \mathbf{x} ,


待决策样本的预处理

$\begin{cases} \text{若 } f(\mathbf{x}) = \text{sgn}[g(\mathbf{x})] = +1, & \text{则决策 } \mathbf{x} \text{ 为第1类} \\ \text{若 } f(\mathbf{x}) = \text{sgn}[g(\mathbf{x})] = -1, & \text{则决策 } \mathbf{x} \text{ 为第2类} \end{cases}$

主要内容

- 1 两类别分类问题：线性可分情况
- 2 两类别分类问题：近似线性可分情况
- 3 多类别的线性SVM
- 4 应用举例

1.例 二维特征空间、两类别、线性不可分情况




适用：含噪声的训练样本；

容许对训练样本进行线性错分

2. 广义线性SVM—最优分类面的求取

(1) 问题描述

已知：训练样本集 $\{\mathbf{x}_i, y_i\}, i = 1, \dots, N$ $\mathbf{x}_i \in R^d$
类别标号 $y_i \in \{-1, 1\}$
估计：广义最优线性判别函数 $g(\mathbf{x}) = \mathbf{w} \cdot \mathbf{x} + b$



(2)目标函数的构造

折中：“最大分类间隔 + 训练样本集的最小错分程度”

归一化判别函数 $g(\mathbf{x}) = \mathbf{w} \cdot \mathbf{x} + b$

对所有训练样本，引入松弛变量 $\xi_i \geq 0, i = 1, \dots, N$

$$\text{for } i = 1, \dots, N \quad \begin{cases} g(\mathbf{x}_i) = \mathbf{w} \cdot \mathbf{x}_i + b \geq 1 - \xi_i & \text{若 } y_i = +1 \\ g(\mathbf{x}_i) = \mathbf{w} \cdot \mathbf{x}_i + b \leq -(1 - \xi_i) & \text{若 } y_i = -1 \end{cases}$$

$$\rightarrow y_i \cdot g(\mathbf{x}_i) + \xi_i \geq 1$$

$$\rightarrow y_i \cdot [\mathbf{w} \cdot \mathbf{x}_i + b] \geq 1 - \xi_i$$


目标函数构造的基本思想

$$\left\{ \begin{array}{ll} \text{分类间隔} margin = \frac{2}{\|w\|} \text{ 尽可能大} & \Leftrightarrow \frac{1}{2}(w \cdot w) \downarrow \\ \text{训练样本集的错分程度尽可能低} & \Leftrightarrow \sum_{i=1}^N \xi_i \downarrow \end{array} \right.$$

原始目标函数

$$\text{松弛因子向量 } \xi = [\xi_1 \quad \cdots \quad \xi_N]^T$$

C - SVC (标准SVC)


$$\begin{array}{ll} \min_{w, \xi, b} & \phi(w, \xi, b) = \frac{1}{2}(w \cdot w) + C \left(\sum_{i=1}^N \xi_i \right) \\ \text{s.t.} & \begin{cases} -[y_i \cdot (w \cdot x_i + b) - 1 + \xi_i] \leq 0 \\ -\xi_i \leq 0 \end{cases} \quad i = 1, 2, \dots, N \end{array}$$

C > 0 -- 模型的超参数，控制错分样本的惩罚程度

(3)目标函数的求解

构造**Lagrange**辅助目标函数，将**原始问题**转化为**对偶问题**.

$$\left\{ \begin{array}{l} \min \quad L(\mathbf{w}, b, \xi; \boldsymbol{\alpha}, \boldsymbol{\mu}) = \frac{1}{2}(\mathbf{w} \cdot \mathbf{w}) + C \left(\sum_{i=1}^N \xi_i \right) \\ \quad \quad \quad - \sum_{i=1}^N \alpha_i \{ y_i \cdot [\mathbf{w} \cdot \mathbf{x}_i + b] - 1 + \xi_i \} - \sum_{i=1}^N \mu_i \xi_i, \\ \alpha_i \geq 0, \quad i = 1, 2, \dots, N \\ \mu_i \geq 0, \quad i = 1, 2, \dots, N \end{array} \right.$$

其中**非负**Lagrange乘子向量 $\begin{cases} \boldsymbol{\alpha} = [\alpha_1 & \cdots & \alpha_N]^T \\ \boldsymbol{\mu} = [\mu_1 & \cdots & \mu_N]^T \end{cases}$

$$\text{显然: } L(\mathbf{w}, b, \xi; \boldsymbol{\alpha}, \boldsymbol{\mu}) \leq \phi(\mathbf{w}, \xi, b) = \frac{1}{2}(\mathbf{w} \cdot \mathbf{w}) + C \left(\sum_{i=1}^N \xi_i \right)$$

原始问题等价于： $\min_{\mathbf{w}, b, \xi} \max_{\boldsymbol{\alpha}, \boldsymbol{\mu}} L(\mathbf{w}, b, \xi; \boldsymbol{\alpha}, \boldsymbol{\mu})$

原始目标函数

C - SVC (标准SVC)


$$\begin{aligned} \min_{\mathbf{w}, \xi, b} \quad & \phi(\mathbf{w}, \xi, b) = \frac{1}{2}(\mathbf{w} \cdot \mathbf{w}) + \mathbf{C} \left(\sum_{i=1}^N \xi_i \right) \\ \text{s.t.} \quad & \begin{cases} -[y_i \cdot (\mathbf{w} \cdot \mathbf{x}_i + b) - 1 + \xi_i] \leq 0 \\ -\xi_i \leq 0 \end{cases} \quad i = 1, 2, \dots, N \end{aligned}$$

对偶目标函数

$$\begin{aligned} \max_{\alpha} \quad & \sum_{i=1}^N \alpha_i - \frac{1}{2} \sum_{j=1}^N \sum_{i=1}^N \alpha_i \alpha_j y_i y_j (\mathbf{x}_j \cdot \mathbf{x}_i) \\ \text{s.t.} \quad & \begin{cases} (1) \quad \sum_{i=1}^N \alpha_i y_i = 0 \\ (2) \quad 0 \leq \alpha_i \leq C, \quad i = 1, \dots, N \end{cases} \end{aligned}$$

解得 $\boldsymbol{\alpha}^* = [\alpha_1^*, \dots, \alpha_N^*]^T$

样本的错分与正确分类



- — 第一类样本
- × — 第二类样本
- ⊙ ⊙ — 一边界支持向量
- ⊠ ⊠ — 错分支持向量

训练样本集 T 的划分 基于 $\alpha^* = [\alpha_1^* \cdots \alpha_N^*]^T$ 中各分量取值的三种可能划分

- $\alpha_i^* = 0$ 训练样本 x_i 为**非支持向量**
- $0 < \alpha_i^* < C$ 训练样本 x_i 为**边界支持向量** (位于 H_1, H_2 超平面)
- $\alpha_i^* = C$ 训练样本 x_i 为**错分支持向量**

训练样本集 = { **非支持向量** } \cup { **边界支持向量** } \cup { **错分支持向量** }

广义线性SVM中，判别函数的最优参数 w^* 、 b^* 的确定：

$$A. \quad w^* = \sum_{i=1}^N \alpha_i^* y_i x_i$$

对 w^* 有贡献的只有占少数的非零 α_i^*

对应非零 α_i^* 的训练样本就称为**支持向量**(*Support Vector*)

B. b^* 的确定

找到所有**边界支持向量**，构成集合：

$$U = \{ (x_i, y_i) \mid (x_i, y_i) \in \text{训练集 } T, \text{ 并且 } 0 < \alpha_i^* < C \}$$


对于 $\forall (x_i, y_i) \in U$ ，必有： $y_i = w^* \cdot x_i + b^*$

为了确保稳定性，取平均：

$$b^* = \frac{1}{\#U} \sum_{(x_i, y_i) \in U} [y_i - w^* \cdot x_i]$$

$\#U$ ----集合 U 中元素数目(或表示为 $|U|$)

(4) 广义线性SVM的判别函数



广义最优分类决策函数：

$$f(\mathbf{x}) = \text{sgn} \left[\left(\mathbf{w}^* \cdot \mathbf{x} \right) + b^* \right] = \text{sgn} \left\{ \sum_{i=1}^N \alpha_i^* y_i \left(\mathbf{x}_i \cdot \mathbf{x} \right) + b^* \right\}$$

广义线性SVM (C - SVC) 原始问题的目标函数

$$\begin{aligned} \min_{\mathbf{w}, \xi, b} \quad & \phi(\mathbf{w}, \xi, b) = \frac{1}{2}(\mathbf{w} \cdot \mathbf{w}) + C \left(\sum_{i=1}^N \xi_i \right) \\ \text{s.t.} \quad & \begin{cases} -[y_i \cdot (\mathbf{w} \cdot \mathbf{x}_i + b) - 1 + \xi_i] \leq 0 \\ -\xi_i \leq 0 \end{cases} \quad i = 1, 2, \dots, N \end{aligned}$$

非负Lagrange乘子向量的最优解: $\boldsymbol{\alpha}^* = [\alpha_1^* \quad \cdots \quad \alpha_N^*]^T$

$$\text{最优分类边界 } (\mathbf{w}^* \cdot \mathbf{x}) + b^* = 0 \quad \begin{cases} \mathbf{w}^* = \sum_{i=1}^N \alpha_i^* y_i \mathbf{x}_i \\ b^* = \frac{1}{\#U} \sum_{(\mathbf{x}_i, y_i) \in U} [y_i - \mathbf{w}^* \cdot \mathbf{x}_i] \\ U = \{(\mathbf{x}_i, y_i) \mid (\mathbf{x}_i, y_i) \in \text{训练集 } T, \text{ 并且 } 0 < \alpha_i^* < C\} \end{cases}$$

$$\text{判别函数 } g(\mathbf{x}) = (\mathbf{w}^* \cdot \mathbf{x}) + b^* = \sum_{i=1}^N \alpha_i^* y_i (\mathbf{x}_i \cdot \mathbf{x}) + b$$

$$f(\mathbf{x}) = \text{sgn}[(\mathbf{w}^* \cdot \mathbf{x}) + b^*] = \text{sgn} \left\{ \sum_{i=1}^N \alpha_i^* y_i (\mathbf{x}_i \cdot \mathbf{x}) + b^* \right\}$$

[线性C-SVC算法]

(1) 给定训练样本集 $T = \{(\mathbf{x}_1, y_1), \dots, (\mathbf{x}_N, y_N)\}$,

训练样本的
预处理

其中 $\mathbf{x}_i \in R^d, y_i \in \mathcal{Y} = \{1, -1\}, i = 1, \dots, N$

(2) 选择适当的惩罚参数 C [问题: 如何选择参数 C]

(3) 构造并求解凸二次规划问题

$$\left\{ \begin{array}{l} \min_{\alpha} \quad \frac{1}{2} \sum_{j=1}^N \sum_{i=1}^N \alpha_i \alpha_j y_i y_j (\mathbf{x}_j \cdot \mathbf{x}_i) - \sum_{i=1}^N \alpha_i \\ s.t. \quad \left\{ \begin{array}{l} (1) \quad \sum_{i=1}^N \alpha_i y_i = 0 \\ (2) \quad 0 \leq \alpha_i \leq C \quad \text{对于 } i = 1, \dots, N \end{array} \right. \end{array} \right.$$

得解 $\boldsymbol{\alpha}^* = [\alpha_1^*, \dots, \alpha_N^*]^T$

(4) 估计 $\mathbf{w}^* = \sum_{i=1}^N \alpha_i^* y_i \mathbf{x}_i$

(5) 估计 b^*

找到所有**边界支持向量**，构成集合：

$$U = \{(\mathbf{x}_i, y_i) \mid (\mathbf{x}_i, y_i) \in \text{训练集 } T, \text{ 并且 } 0 < \alpha_i^* < C\}$$

对于 $\forall (\mathbf{x}_i, y_i) \in U$ ，必有： $y_i = \mathbf{w}^* \cdot \mathbf{x}_i + b^*$

$$b^* = \frac{1}{\#U} \sum_{i \in U} \left[y_i - \sum_{j=1}^N \alpha_j^* y_j (\mathbf{x}_j \cdot \mathbf{x}_i) \right]$$

(6) 分类模型的使用： $g(\mathbf{x}) = (\mathbf{w}^* \cdot \mathbf{x}) + b^* = \sum_{i=1}^N \alpha_i^* y_i (\mathbf{x}_i \cdot \mathbf{x}) + b^*$

对于未知类别的测试样本 \mathbf{x} ,

$$\begin{cases} \text{若 } f(\mathbf{x}) = \text{sgn}[g(\mathbf{x})] = +1, & \text{则决策 } \mathbf{x} \text{ 为第1类} \\ \text{若 } f(\mathbf{x}) = \text{sgn}[g(\mathbf{x})] = -1, & \text{则决策 } \mathbf{x} \text{ 为第2类} \end{cases}$$

待决策样本
的预处理